

Universität Hamburg  
Department Informatik  
Knowledge Technology, WTM

# Erfassen der Morphologie von in Textform vorliegender natürlicher Sprache

Proseminararbeit

Proseminar: Künstliche Intelligenz

Louis Kobras

Matr.Nr. 6658699

4kobras@informatik.uni-hamburg.de

3. Juli 2015



## Abstract

Seit Jahrzehnten schon beschäftigen sich Forscher damit, den Computer dem Menschen näher zu bringen. Ein wichtiger Bestandteil dieses Prozesses ist dabei die Sprachverarbeitung.

Ziel dieser Arbeit ist, Licht auf den Prozess des Verständnisses eines Computers von natürlicher Sprache zu werfen.

Zu diesem Zweck wird der Begriff der natürlichen Sprache in seine Komponenten zerlegt, die einzeln analysiert und in dieser Form von nichtkomplexen Automaten verarbeitet werden können.

*Einbindung der Ergebnisse.*

## Inhaltsverzeichnis

<b>1</b>	<b>Einführung</b>	<b>2</b>
1.1	Was bisher geschah: Sprachverarbeitung im Kontext der historischen Artificial Intelligence . . . . .	2
1.2	ELIZA als Beispiel für frühe Sprachverarbeitung . . . . .	3
<b>2</b>	<b>Was ist natürliche Sprache?</b>	<b>3</b>
<b>3</b>	<b>Parsing der Morphologie mithilfe von deterministischen endlichen Automaten</b>	<b>4</b>
<b>4</b>	<b>Morphologie-Analyse am Beispiel von <i>Sirius</i></b>	<b>6</b>
4.1	Sirius . . . . .	6
<b>5</b>	<b>Praktischer Nutzen der Textverarbeitung</b>	<b>6</b>
<b>6</b>	<b>Schlussfolgerung</b>	<b>7</b>
	<b>Quellenverzeichnis</b>	<b>8</b>

# 1 Einführung

Schon seit etwa achtzig Jahren beschäftigen sich Forscher mit dem Thema der Künstlichen Intelligenz, und nicht weniger Zeit ist in die Theorie der Sprachverarbeitung investiert worden. Sprachverarbeitung liegt in zwei Formen vor, die in ihren jeweiligen Anwendungsgebieten für eine erhebliche Steigerung der Effektivität der Nutzer sorgen können: Verarbeitung *gesprochener Sprache* (Speech Recognition) und *Textverarbeitung* (Text Processing). Beide Aspekte fallen unter das *Verarbeiten natürlicher Sprache* (Natural Language Processing). Diese Arbeit wird sich mit dem Verarbeiten natürlicher Sprache in Textform beschäftigen.

Zwar ist Kommunikation durch Texteingabe nicht so schnell und dynamisch anwendbar wie gesprochene Anweisungen, dennoch aber ist sie ein wichtiger Schritt dorthin. Wir werden sehen, wie natürliche Sprache aufgebaut ist, wie sie durch Verwendung von Deterministischen Automaten und Markov-Ketten analysiert werden kann, und wie mit den erhaltenen Informationen verfahren werden kann.

## 1.1 Was bisher geschah: Sprachverarbeitung im Kontext der historischen Artificial Intelligence

Die Grundsteine für Künstliche Intelligenz wurden 1936 von Turing und darauf aufbauend in den 40ern und 50ern gelegt (McCulloch und Pitts (1943), Chomsky (1956) et al.).

Ende der 50er Jahre hatten sich daraus zwei parallele Zweige für die Sprachverarbeitung gebildet: Das formale Paradigma und der stochastische Ansatz ([2]).

Während das formale Paradigma seinen Schwerpunkt auf formale Sprachen und das Parsen von Schlüsselwörtern gelegt hatte, lag der Schwerpunkt des anderen Ansatzes auf der Berechnung der Wahrscheinlichkeit des Auftretens bestimmter Wörter anhand eines umfassenden Lexikons und der Anwendung Bayesscher Methoden auf die einzelnen Zeichen.

Während der stochastische Zweig weitestgehend erhalten blieb, teilte sich der formale Zweig zu Beginn der 70er Jahre in drei Pfade auf. Der stochastische Zweig begann, versteckte Markov-Modelle (HMM) bei seiner Analyse zu nutzen. Ein Logik-basierender Zweig befasste sich mit der Vereinheitlichung der Struktur von Sprache und nutzte dabei eine sog. *Definite Clause Grammar*, woraus sich später Prolog entwickeln würde. Der Zweig, der sich mit natürlicher Sprache befasste, versuchte, Text-Kommandos und Konzepte so umzusetzen, dass Maschinen eine semantische Grundlage mitgegeben werden konnte, auf der die Interpretation aufbauen würde. Der Diskurs-Zweig verwendete die Betrachtung von Substrukturen im Diskurs von Sprachen und der Automatisierung von Referenzen.

Die 80er und 90er Jahre beschäftigten sich Wahrscheinlichkeitsmodellen und Modellen, die sich deterministische, endliche Automaten zur Analyse zu Nutzen machten.

Ende des 20. Jahrhunderts hatte sich das Wahrscheinlichkeitsmodell als Standard durchgesetzt. Die Forschung in diesem Feld wurde durch das Aufkommen des Internet und auf kommerzieller Basis durch Entwicklung der Technologie weiter vorangetrieben.

## 1.2 ELIZA als Beispiel für frühe Sprachverarbeitung

ELIZA ist ein frühes Programm zur Sprachverarbeitung (Weizenbaum, 1966). Das Programm wendet simples Parsing und Mustererkennung an, um Schlüsselwörter aus einem gegebenen Satz zu extrahieren und darauf aufbauend eine Antwort zu generieren. ELIZA arbeitet als Rogativer Psychologe, d.h. man erzählt ihr etwas und sie stellt eine darauf basierende Frage.

Das Programm ist sehr simpel, und ELIZA benötigt fast keine Informationen, um zu funktionieren. Durch ihre Arbeitsweise kann sie ein natürliches Gespräch mit einem Psychologen nur durch das Wiederholen von Sätzen in Frageform erfolgreich simulieren. Dies tut sie, indem sie mit einem simplen Such-Algorithmus den vom Benutzer eingegebenen Text mit einer Liste von Stichworten vergleicht und anhand derer eine vordefinierte Antwort zurückliefert. Zugegebenermaßen ist die Art der Antworten derart gut konstruiert, dass viele der Probanden, die in den 60er Jahren ersten Kontakt mit ELIZA hatten, der Ansicht waren, sie wäre ein denkendes Programm, fähig zu höherer Intelligenz, und glaubten selbst dann noch an ihre Fähigkeiten, als man ihnen ihre Funktionsweise offenbarte (Weizenbaum, 1976).

Dennoch ist ihre künstliche Intelligenz in keiner Weise mit tatsächlicher künstlicher Intelligenz zu vergleichen. Während ELIZA ein simples Key-Value-Pair-matching-Verfahren anwendet (sie sucht sich eine Antwort anhand eines erkannten Stichwortes), wird von einer KI erwartet, tatsächlich zu verstehen, was zu ihr gesagt wird. Sie muss also nicht nur ein Wort wiedererkennen, sondern auch wissen, was damit gemeint ist. Desweiteren muss eine KI auch in der Lage sein, Wörter in ihrer flexierten Form wiederzuerkennen, eingebaut in natürliche Sprache. Auf einen Aspekt dieser Erkennung wird sich diese Arbeit beziehen.

## 2 Was ist natürliche Sprache?

*„By 'natural language' we mean a language that is used for everyday communication by humans; languages such as English, Hindi, or Portuguese. In contrast to artificial languages such as programming languages and mathematical notations, natural languages have evolved as they pass from generation to generation. and are hard to pin down with explicit rules.“ [1]*

So definieren Steven Bird et. al. den Begriff *natürliche Sprache*. Eine Sprache ist eine Konvention zur Kommunikation bestehend aus einer Grammatik, einem Vokabular und einem Verwendungskontext.

Eine natürliche Sprache ist eine Sprache, die sich im Verlauf der Zeit aus der Kommunikation zwischen Menschen entwickelt hat. Durch die permanente Entwicklung einer Sprache verändert sich permanent die Bedeutung und Verwendung von Wörtern, andere Wörter werden neu hinzugefügt, wieder andere fallen heraus. So wurde zum Beispiel das Wort Gebäudereinigungsfachkraft erst vor relativ kurzer Zeit in den aktiven Wortschatz seiner Sprache aufgenommen, während das Wort archaisch für 'veraltet' oder 'altertümlich' kaum noch Verwendung findet. Das erste Beispiel hat aus Gründen der politischen Korrektheit nicht nur Einzug in die deutsche Sprache als neue

Bezeichnung gefunden, sondern auch seinen Vorgänger ersetzt.

Bird et. al. nahmen ebenfalls Bezug auf künstliche Sprachen. Programmiersprachen und mathematische Notationen sind, ebenso wie natürliche Sprachen, als Verbindung aus Grammatik, Wortschatz und Verwendung darstellbar. Der Unterschied zu den natürlichen Sprachen ist jedoch, dass diese Sprachen feststehen. In der Sprache der Mathematik findet außer in Fachkreisen kaum noch eine Veränderung statt. Ebenso verhält es sich mit dem täglich verwendeten Java. Mit jedem Update gibt es eine handvoll Änderungen, jedoch nimmt kaum eine dieser Änderungen Einfluss auf den alltäglichen Gebrauch der Sprache.

Die Eigenschaft von natürlichen Sprachen, dynamisch zu sein, macht es schwer, sie in kompakten Regeln klar zu formulieren. Um es dennoch zu können, wird eine Sprache in folgende sechs Teilgebiete aufgeteilt, die jedes für sich erfasst und bearbeitet werden kann: Morphologie, Syntax, Semantik, Pragmatik, Diskurs und Mehrdeutigkeit.

Für die gesprochene Sprache kommt der Punkt der Phonologie hinzu.

Unter **Morphologie** verstehen wir die Veränderung des Wortes nach Anwendung der Grammatik.

Unter **Syntax** verstehen wir den strukturellen Aufbau eines Satzes, etwa dass ein Verb nie vor einem Subjekt steht.

Unter **Semantik** verstehen wir [...]

Unter **Pragmatik** verstehen wir [...]

Unter **Diskurs** verstehen wir [...]

Unter **Mehrdeutigkeit** verstehen wir, dass ein Wort verschiedene Bedeutungen abhängig vom Kontext haben kann.

Unter **Phonologie** verstehen wir, dass sich je nach Aussprache die Bedeutung eines Wortes ändern kann.

Aus Gründen der Übersichtlichkeit wird hier nur auf Morphologie eingegangen.

### 3 Parsing der Morphologie mithilfe von deterministischen endlichen Automaten

Zum Parsing der Morphologie sei zunächst gesagt, was unter dem Begriff der Morphologie zu verstehen ist. Die Morphologie ist die Festlegung all jener Regeln, nach denen sich ein Wort unter Flexion verändert. Dies geschieht über das Hinzufügen von *Morphemen*. Ein Morphem ist alles das, was als atomarer Bestandteil eines Wortes gelesen werden kann: Wortstamm, Flexionsendungen, Affixe. [2] führt als Beispiel das Wort *fox* sowie dessen Pluralform *foxes* an, welches sich als folgende Kette von Morphemen darstellen lässt:

$$\begin{array}{ccc} fox & & es \\ \text{Stamm} & +N & +PL \end{array}$$

Wie man sehen kann, sind mehr Morpheme gelistet, als das Wort Flexionsbausteine hat. Zu den Morphemen zählen ebenfalls Zeichen, die grammatikalische Informationen enthalten wie beispielsweise, dass es sich um ein Nomen handelt (+N). Mithilfe von

Konventionen über die Stelligkeit, also die Reihenfolge, und Nomenklatur der Morpheme ist es möglich, wahlweise kaskadierende oder verkettete endliche, deterministische Automaten (i.F. DFAs) zu konstruieren, deren Zweck darin besteht, ein Wort in seine Morpheme zu zerlegen und uns somit mit sämtlichen grammatikalischen Informationen über dieses Wort zu versorgen.

Es liegt auf der Hand, dass eine Automatenkette, die sämtliche Wörter einer Sprache korrekt erkennen soll, sehr lang ist. Wählt man statt der Verkettung die Kaskadierung der Automaten, d.h. man konstruiert einen äquivalenten, größeren Automaten, der mehrere kleinere DFAs zusammenfasst, so wird die Kette zwar kürzer (durch genügend Rekonstruktion lässt sich jede Kette von DFAs in einem großen DFA zusammenfassen), da jedoch die Anzahl der Zustände und Kanten äquivalent ist, wird das Konstrukt ungleich komplexer.

Zu Veranschaulichung wird an dieser Stelle ein kleiner DFA eingefügt, der das Wort *Nachkommastellen* auf seine Morpheme reduzieren soll.




Abbildung 1: DFA zur Zerlegung des Wortes *Nachkommastellen* in seine Morpheme

Dies ist ein sehr allgemeiner DFA, um Nomen zu erkennen. Zuerst wird geprüft, ob der erste Buchstabe groß geschrieben ist, was eine Voraussetzung für Nomen in der deutschen Sprache ist und das Morphem +N zurückliefert. Anschließend wird das Wort nach einer Zeichenkette durchsucht, die in der Liste der dem Programm bekannten Nomen steht. Da *komma* vor *stelle* steht, wird es als gültiger Stamm akzeptiert. Allerdings ist dies eine Schwachstelle dieses DFA, welcher auch fälschlicherweise *stelle* als Stamm erkennen könnte. Dieser Prozess liefert uns das Stamm-Morphem zurück.

An dieser Stelle hat der Automat erfolgreich ein Nomen erkannt und kann den Prozess beenden, wenn das Wort zu ende ist. Ist das Wort noch nicht zu ende, so prüft der Automat die verbliebenen Zeichenketten zunächst darauf, ob das Plural-Morphem vorliegt. In unserem Fall ist dieses Morphem nur der Buchstabe *n*, bei manchen Wörtern kann es sich aber auch um beispielsweise die Zeichenkette *en* handeln. Sind dann noch Zeichen übrig, werden diese darauf geprüft, ob es sich um gültige Affixe handelt. Diese werden in *q3* allesamt herausgefiltert und liefern ihr Morphem zurück. Sind nach dem Prüfen auf Affixe noch Zeichen übrig, bricht der Automat ab und akzeptiert das Wort nicht. Dies kann bei der hier gewählte Implementierung sowohl daran liegen, dass ein morphologischer Sonderfall vergessen wurde, als auch daran, dass es sich nicht um ein gültiges Wort handelt. Ist das Wort allerdings zu ende, akzeptiert der Automat das Wort und liefert uns dessen Morphem-Kette zurück, welche in unserem Beispiel wie folgt aussieht:

N    nach    komma    stelle    n  
N   +Pref   +Stamm   +Suf   +PL

Wie hier zu sehen ist, ist bereits bei einem einzelnen Wort viel zu beachten. Hinzu kommt, dass hier nur eine Wortklasse abgedeckt wurde. Kommen noch andere Wort-

klassen, wie beispielsweise Verben, hinzu, steigt die Komplexität der Automatenkette exponentiell.

Als Ansatzpunkt wäre hier allerdings anzumerken, dass der DFA mit einer Kante von  $q_0$  zu einem nicht angegebenen Zustand versehen werden kann, die als Beschriftung hat: "1. Buchstabe  $\rightarrow$  groß". Diese Kante würde eine Kaskade beginnen, durch die ein Wort durch die DFAs für sämtliche Wortklassen durchgereicht wird.

Die Operationen, die erforderlich sind, um einen String derart zu zerlegen, sind in höheren Programmiersprachen bereits enthalten. Ebenso können gewissen Morpheme mit regulären Ausdrücken (*regular expressions*/ RegEx) erkannt werden.

Da nun bekannt ist, wie aus einem gelesenen String ein verarbeitbarer Datensatz geworden ist, folgt ein Einblick in die Implementierung der Textanalyse bei der Open Source-Software *Sirius*.

## 4 Morphologie-Analyse am Beispiel von *Sirius*

Diese drei Namen sind Namen von Open Source Sprachverarbeitungssoftware. Wir werden diese drei Pakete untersuchen und ihre Gemeinsamkeiten bezüglich der Sprachanalyse ermitteln.

- wird Code-Beispiele enthalten

### 4.1 Sirius

Für die meisten Linux-Distributionen verwendbar  
Sprache: Python, C++, Shell

## 5 Praktischer Nutzen der Textverarbeitung

Anhand von ELIZA (1.2) wurde gezeigt, wie die Kinderschuhe der Sprachverarbeitung ausgesehen haben. Mithilfe von Sirius (4.1) wurde gezeigt, wie ein Teil der Sprachverarbeitung heute aussieht. Doch was kommt nun? Was hat man davon, dass Computer Menschen verstehen können? Ein Beispiel, welches ich an dieser Stelle aus Eigeninteresse an der Thematik vorstellen möchte, ist die Weiterentwicklung des Chat-Bots: Die Künstliche Intelligenz von Videospiel-NPCs.

Während ein Chat-Bot eine Sammlung semi-intelligenter, auf Key-Value-Pairing basierender Algorithmen zum Durchsuchen von Speicherdaten, etwa in Form einer Text-Datei, ist, ist ein NPC die Illusion einer lebenden Entität in einer fiktiven Welt. Die Abkürzung *NPC* steht für den englischen Ausdruck *Non-Player-Character*, also eine Figur, die nicht vom Spieler selber gesteuert wird.



## **6 Schlussfolgerung**

*evtl mit Ausblick zusammenziehen*

- Fazit: Status Quo
- Heutige Möglichkeiten
- theoretische Möglichkeiten
- Ansätze für Weiterentwicklung

## Literatur

- [1] Ewan Klein; Edward Loper; Steven Bird. *Natural language processing with Python*. O'Reilly Media, Inc, 2009.
- [2] James H. Martin; Daniel Jurafsky. *Speech and Language Processing*. Prentice Hall, 2009.
- [3] Clarity Lab. Sirius, 2015.
- [4] Iain Last; Axel Glaser; Stefan Scheit; Tarmo Ploom. Processing chains in system of systems. In *Mesoca 2014: 8th IEEE International Symposium on the Maintenance and Evolution of Service-Oriented and Cloud-Based Systems*, 2014.
- [5] Peter Norvig; Stuart Russel. *Artificial Intelligence: A Modern Approach*. Prentice Hall, 2009.